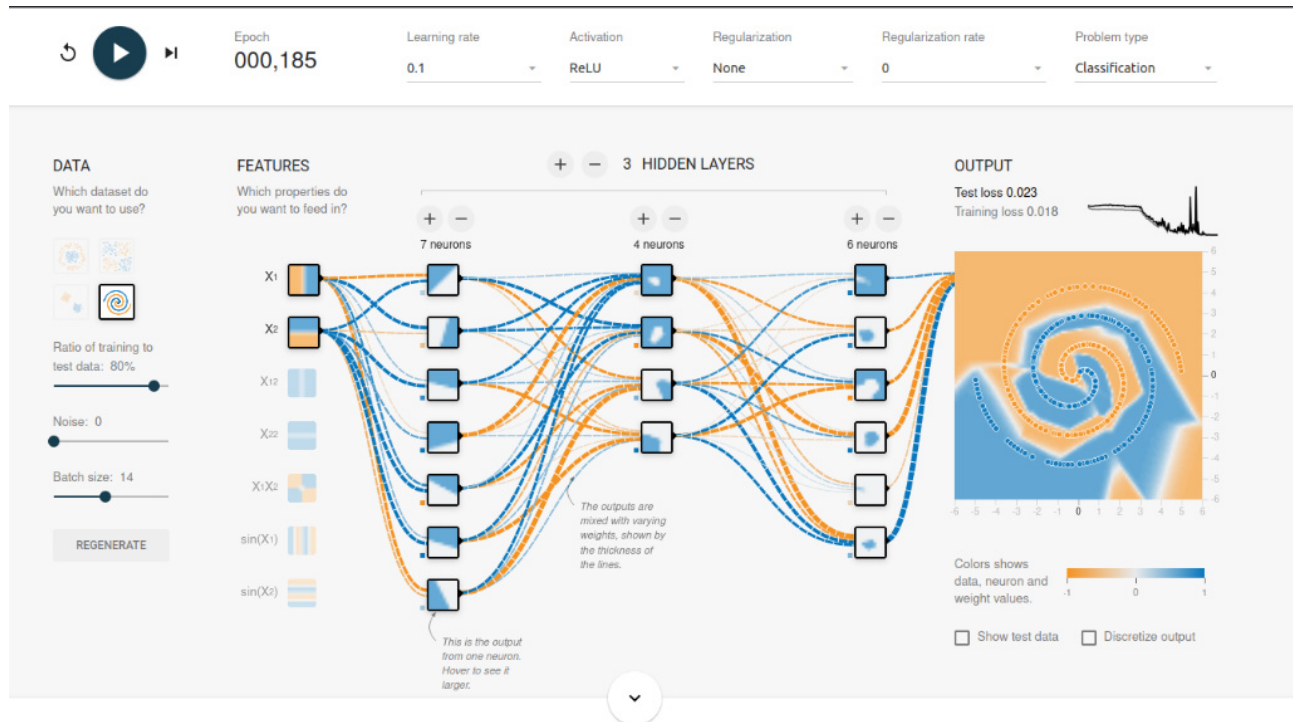


Atividade: Análise da Rede Neural Playground (Dataset Spiral)



1. Screenshot da Solução

A imagem a seguir apresenta a arquitetura e os parâmetros da Rede Neural Artificial configurada para resolver o complexo problema de classificação do dataset "Spiral", alcançando um Test Loss (Perda de Teste) de **0.023** em apenas 185 *epochs*.

Parâmetros Utilizados:

- **Entradas (Features):** X1 e X2
- **Camadas Ocultas (Hidden Layers):** 3
 - Camada 1: 7 Neurônios
 - Camada 2: 4 Neurônios
 - Camada 3: 6 Neurônios
- **Taxa de Aprendizagem (Learning Rate):** 0.1
- **Função de Ativação (Activation):** ReLU
- **Regularização (Regularization):** Nenhuma

2. Análise do Impacto dos Parâmetros

O sucesso na resolução do dataset "Spiral" demonstra o papel crítico de cada parâmetro na modelagem de relações não lineares complexas.

A. Número de Camadas (Profundidade)

- **Impacto:** Para resolver o padrão espiral, que é altamente não linear e entrelaçado, uma rede **profunda** (com **3 camadas** ocultas) foi fundamental. Cada camada atua como um "extrator de características", aprendendo representações mais abstratas dos dados de entrada. A profundidade foi essencial para "desenrolar" o padrão.

B. Número de Neurônios em Cada Camada (Largura/Capacidade)

- **Impacto:** O número de neurônios (7-4-6 na solução) define a **capacidade de representação** da rede. Uma arquitetura bem balanceada é crucial: capacidade insuficiente causa *underfitting*, e excesso aumenta o risco de *overfitting*. A configuração utilizada atingiu o equilíbrio para modelar a complexidade do dataset.

C. Tipo de Ativação

- **Impacto:** A função **ReLU (Rectified Linear Unit)** é essencial por introduzir a **não-linearidade** necessária. Sem ativação não linear, múltiplas camadas seriam inúteis para este problema. A ReLU é eficiente, permitindo que a rede aprenda as fronteiras de decisão complexas rapidamente.

D. Learning Rate (Taxa de Aprendizagem)

- **Impacto:** O valor de **0.1** representa um passo de ajuste de peso adequado. Uma taxa muito alta causaria instabilidade (o *loss* saltaria), e uma muito baixa tornaria o aprendizado extremamente lento. Este valor permitiu uma convergência rápida e precisa, resultando no baixo *Test Loss*.

E. Fator de Regularização

- **Impacto:** A regularização (L1 ou L2) é usada para **prevenir o overfitting**, penalizando pesos grandes. O fato de **Nenhuma** ter sido usada na sua solução (com sucesso) indica que a arquitetura (profundidade e largura) já era bem dimensionada para o problema, e o treinamento parou antes que o modelo começasse a memorizar demais os dados de treino.